Локализация и интернационализация программного обеспечения Инструментарий Современного Программиста

Иван Трепаков

NSU Sys.Pro

American Standard Code for Information Interchange

```
$ ascii -d
                                                           96 `
    0 NUL
              16 DLE
                        32
                                 48 0
                                         64 @
                                                  80 P
                                                                  112 p
    1 S0H
              17 DC1
                        33 !
                                 49 1
                                          65 A
                                                  81 0
                                                           97 a
                                                                  113 q
    2 STX
              18 DC2
                        34 "
                                 50 2
                                          66 B
                                                  82 R
                                                           98 b
                                                                  114 r
    3 ETX
              19 DC3
                        35 #
                                 51 3
                                          67 C
                                                  83 S
                                                           99 c
                                                                  115 s
    4 E0T
              20 DC4
                        36 $
                                 52 4
                                         68 D
                                                  84 T
                                                          100 d
                                                                  116 t
    5 ENQ
              21 NAK
                        37 %
                                 53 5
                                          69 E
                                                  85 U
                                                          101 e
                                                                  117 u
    6 ACK
              22 SYN
                        38 &
                                 54 6
                                          70 F
                                                  86 V
                                                          102 f
                                                                  118 v
    7 BEL
              23 ETB
                        39 '
                                                  87 W
                                                          103 g
                                 55 7
                                          71 G
                                                                  119 w
    8 BS
              24 CAN
                        40 (
                                 56 8
                                          72 H
                                                  88 X
                                                          104 h
                                                                  120 x
    9 HT
              25 EM
                        41 )
                                 57 9
                                          73 I
                                                  89 Y
                                                          105 i
                                                                  121 y
   10 LF
              26 SUB
                        42 *
                                 58 :
                                          74 J
                                                  90 Z
                                                          106 j
                                                                  122 z
   11 VT
              27 ESC
                        43 +
                                 59 ;
                                          75 K
                                                  91 [
                                                          107 k
                                                                  123 {
   12 FF
              28 FS
                        44 ,
                                 60 <
                                          76 L
                                                  92 \
                                                          108 l
                                                                  124 |
   13 CR
              29 GS
                        45 -
                                 61 =
                                          77 M
                                                                   125 }
                                                  93 ]
                                                          109 m
   14 S0
              30 RS
                        46 .
                                 62 >
                                          78 N
                                                  94 ^
                                                          110 n
                                                                   126 ~
                                                  95
   15 SI
              31 US
                        47 /
                                 63 ?
                                          79 0
                                                          111 o
                                                                   127 DEL
```

ASCII

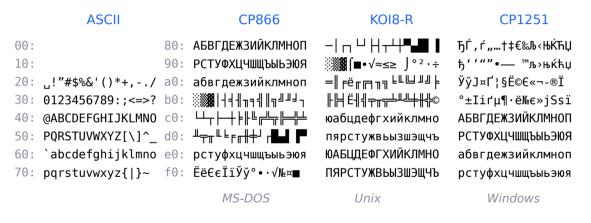
```
00:
10:
20: __!"#$%&'()*+,-./
30: 0123456789:;<=>?
40: @ABCDEFGHIJKLMN0
50: PQRSTUVWXYZ[\]^_
60: `abcdefghijklmno
70: pqrstuvwxyz{|}~
```

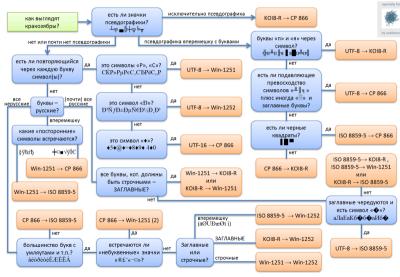
ASCII

```
00: 80: 90: 20: _!"#$%&'()*+,-./ a0: 30: 0123456789:;<=>? b0: 40: @ABCDEFGHIJKLMNO c0: 50: PQRSTUVWXYZ[\]^_ d0: 60: `abcdefghijklmno e0: 70: pqrstuvwxyz{|}~ f0:
```

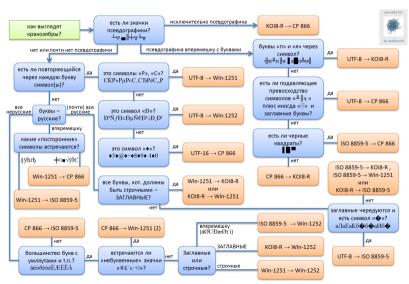
```
ASCII
                           CP866
                  80: АБВГДЕЖЗИЙКЛМНОП
00:
10:
                  90: РСТУФХЦЧШШЪЫЬЭЮЯ
20: ..!"#$%&'()*+,-./ а0: абвгдежзийклмноп
   0123456789:;<=>? b0: 觀|ㅓㅕㅔㄲㅕㅖ॥╗╝╜╛┐
50: PQRSTUVWXYZ[\]^_ d0: ┸╤╥╙╘╒╓╫╪┘┌┸▃▋ ┠
60: `abcdefghijklmno e0: рстуфхцчшщъыьэюя
70: parstuvwxvz{|}~ f0: Ëë€∈ÏiЎў°•·√№¤■
                         MS-DOS
```

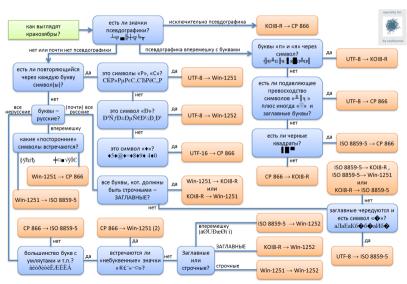
```
ASCII
                      CP866
                                   KOI8-R
                              ╼╿┍┑┖┙┡┥┯┷┼▀▄█▋▐
               80: АБВГДЕЖЗИЙКЛМНОП
00:
                               № (■•√≈≤≥ | °²·÷
10:
               90: РСТУФХЦЧШШЪЫЬЭЮЯ
                               20: ..!"#$%&'()*+,-./ а0: абвгдежзийклмноп
  ╟╠╡Ё╢╣╤╥╦╧╨╩╪╫╬©
юабцдефгхийклмно
пярстужвьызшэщчъ
60: `abcdefghijklmno e0: рстуфхцчшщъыьэюя
                               ЮАБЦДЕФГХИЙКЛМНО
70: parstuvwxvz{|}~ f0: Ëë€eÏiЎў°•·√№¤■
                               ПЯРСТУЖВЬЫЗШЭШЧЪ
                    MS-DOS
                                  Unix
```





```
$ echo "ΟΠΧБΕΡ ЛΧΠ!" \
  | iconv -t cp1251 \
  | iconv -f koi8-r
Hoyaen κyo!
```





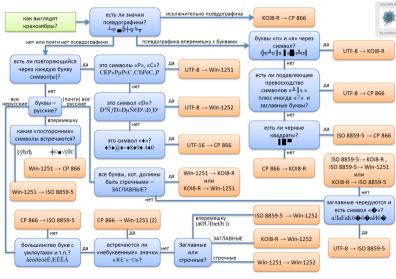
оПХБЕР ЛХП!

```
| iconv -t cp1251 \
        | iconv -f koi8-r
Hoyaen куо!

$ echo "оПХБЕР ЛХП!" \
        | iconv -t koi8-r \
        | iconv -f cp1251
Привет мир!
```

\$ echo "offXFFP JXT!" \

- iconv
- enca
- uchardet



Unicode Standard

- Универсальное кодирование символов
- Количество различных кодов 1 114 112
- Unicode 16.0 (2024 год) использует лишь 154 998

Цели

- Универсальность Содержит все возможные символы современных и древних языков, технических текстов, диакритику и emoji
- Эффективность *Plain text* кодирование в одном из трех стандартных форматов: UTF-32, UTF-16, UTF-8
- Однозначность Каждый код однозначно соответствует единственному символу



Code points

- Кодируют "абстрактные символы"
- ullet Целые числа от 0 до $10 {\rm FFFF}_{16}$
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

Code points

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python

Code points

Hello 🌎!

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python

Code points

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python



```
U+0048 H
            LATIN CAPITAL LETTER H
U + 0.065
            LATIN SMALL LETTER E
U + 0.06C
            LATTN SMALL LETTER L
U + 006C
            LATIN SMALL LETTER L
U+006F
            LATIN SMALL LETTER O
11+0020
            SPACE
U+1F30E
            EARTH GLOBE AMERICAS
11+0.021
            EXCLAMATION MARK
```

Code points

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

Инструменты

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python

Hello 🌎!

```
$ printf 'Hello \U1F30E!' | uniname
U+0048 H
            LATIN CAPITAL LETTER H
U+0065 e
           LATIN SMALL LETTER F
0+0060
           LATTN SMALL LETTER L
U+006C l
           LATIN SMALL LETTER L
U+006F
           LATIN SMALL LETTER O
11+0020
            SPACE
U+1F30E
            EARTH GLOBE AMERICAS
11+0.021
            EXCLAMATION MARK
```

Code points

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

Инструменты

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python

Привет 🌎!

Code points

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

Инструменты

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python

import sys, unicodedata as U

Привет 🌎!

```
H+041F
            CYRILLIC CAPITAL LETTER PE
11 + 0440
            CYRTLLIC SMALL LETTER FR
U + 0438
            CYRTLLIC SMALL LETTER T
U + 0432
            CYRILLIC SMALL LETTER VF
U+0435 e
            CYRTILIC SMALL LETTER TE
11 + 0442
            CYRILLIC SMALL LETTER TE
11 + 0.020
            SPACE
U+1F30E
            FARTH GLOBE AMERICAS
11+0.021
            EXCLAMATION MARK
```

Code points

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

Инструменты

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python

Привет 🌎!

```
$ printf 'Привет \U1F30E!' | uniname
U+041F
            CYRILLIC CAPITAL LETTER PE
U + 0.440
            CYRTLLIC SMALL LETTER FR
11+0438
            CYRTLLIC SMALL LETTER T
U + 0432
            CYRILLIC SMALL LETTER VF
U+0435 e
            CYRILLIC SMALL LETTER IE
11+0442
            CYRILLIC SMALL LETTER TE
11 + 0.020
            SPACE
U+1F30E
            FARTH GLOBE AMERICAS
11+0.021
            EXCLAMATION MARK
```

Code points

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

Инструменты

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python

Йо-йо

Code points

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

Инструменты

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python

Йо-йо

```
U+0439 Й CYRILLIC CAPITAL LETTER SHORT I
U+043E O CYRILLIC SMALL LETTER O
U+002D - HYPHEN-MINUS
U+0438 и CYRILLIC SMALL LETTER I
U+0306 ° COMBINING BREVE
U+043E O CYRILLIC SMALL LETTER O
```

Code points

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

Инструменты

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python

Йо-йо

```
$ printf 'Йο-и\u0306o' | uniname
U+0439 Й CYRILLIC CAPITAL LETTER SHORT I
U+043E ο CYRILLIC SMALL LETTER O
U+002D - HYPHEN-MINUS
U+0438 μ CYRILLIC SMALL LETTER I
U+0306 ઁ COMBINING BREVE
U+043E ο CYRILLIC SMALL LETTER O
```

Code points

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python



Code points

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

Инструменты

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python



Code points

- Кодируют "абстрактные символы"
- Целые числа от 0 до 10FFFF₁₆
- Стандартно записываются в hex с префиксом U+
- Имеют уникальные имена

Инструменты

- uniname (часть пакета uniutils)
- Модуль unicodedata в Python

```
import sys, unicodedata as U
for i, c in enumerate(sys.stdin.read()):
    s = '0' if U.category(c)[0] == 'M' else ''
    print('U+{0:04X}\t{1}{2}\t{3}'
          .format(ord(c), s. c. U.name(c)))
```



\$ printf '\U1F468\u200D\U1F469\u200D\U1F467' \ uniname

U+1F468 👨

MAN

ZERO WIDTH JOINER

U+200D U+1F469 👩 U+200D

WOMAN

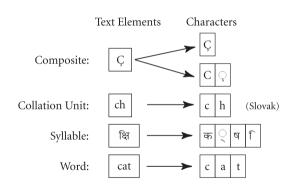
ZERO WIDTH JOINER

U+1F467

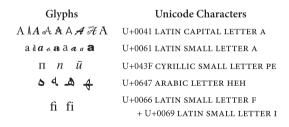
GIRL

Ключевые моменты

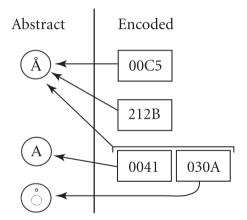
• Текст разбивается на символы



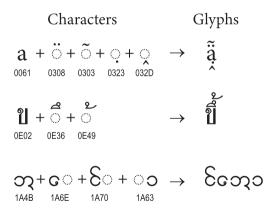
- Текст разбивается на символы
 - Символы ≠ глифы



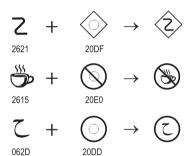
- Текст разбивается на символы
 - Символы ≠ глифы
- Символы кодируются последовательностью code point'ов
 - Code point целое число от 0 до 10FFFF₁₆ соответствующее некоторому абстрактному символу



- Текст разбивается на символы
 - Символы ≠ глифы
- Символы кодируются последовательностью code point'ов
 - Code point целое число от 0 до 10FFFF₁₆
 соответствующее некоторому
 абстрактному символу
- Символы могут комбинироваться



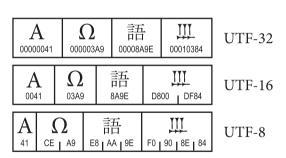
- Текст разбивается на символы
 - Символы ≠ глифы
- Символы кодируются последовательностью code point'ов
 - Code point целое число от 0 до 10FFFF₁₆ соответствующее некоторому абстрактному символу
- Символы могут комбинироваться



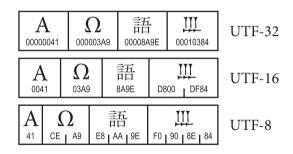
- Текст разбивается на символы
 - Символы ≠ глифы
- Символы кодируются последовательностью code point'ов
 - Code point целое число от 0 до 10FFFF₁₆
 соответствующее некоторому абстрактному символу
- Символы могут комбинироваться
- Правила поиска, сортировки, эквивалентности и других процессов описаны в стандарте

②
$$LJ + A \approx L + J + A$$

- Текст разбивается на символы
 - Символы ≠ глифы
- Символы кодируются последовательностью code point'ов
 - Code point целое число от 0 до 10FFFF₁₆ соответствующее некоторому абстрактному символу
- Символы могут комбинироваться
- Правила поиска, сортировки, эквивалентности и других процессов описаны в стандарте
- Три стандартных формата кодирования code point'oв: UTF-32, UTF-16, UTF-8
 - Code unit Минимальная единица кодирования в формате



UTF-32
Code unit 32-битное значение



UTF-32

Code unit 32-битное значение

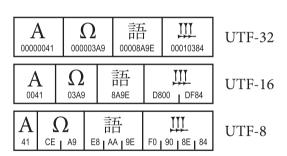
UTF-16

Code unit 16-битное значение

Table 3-5, UTF-16 Bit Distribution

Scalar Value	UTF-16		
xxxxxxxxxxxxx	xxxxxxxxxxxxxx		
000uuuuuxxxxxxxxxxxxxxx	110110wwwwxxxxxx 110111xxxxxxxxxxx		

Note: wwww = uuuuu - 1



UTF-32

Code unit 32-битное значение

UTF-16

Code unit 16-битное значение

Table 3-5. UTF-16 Bit Distribution

Scalar Value	UTF-16	
xxxxxxxxxxxxxx	xxxxxxxxxxxxxx	
000uuuuuxxxxxxxxxxxxxxx	110110wwwwxxxxxx 110111xxxxxxxxxxx	

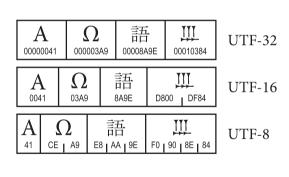
Note: wwww = uuuuu - 1

UTF-8

Code unit 8-битное значение

Table 3-6. UTF-8 Bit Distribution

Scalar Value	First Byte	Second Byte	Third Byte	Fourth Byte
00000000 0xxxxxx	0xxxxxxx			
00000yyy yyxxxxxx	110ууууу	10xxxxxx		
zzzzyyyy yyxxxxxx	1110zzzz	10уууууу	10xxxxxx	
000uuuuu zzzzyyyy yyxxxxxx	11110uuu	10uuzzzz	10уууууу	10xxxxxx



UTF-32

Code unit 32-битное значение

UTF-16

Code unit 16-битное значение

Table 3-5. UTF-16 Bit Distribution

Scalar Value	UTF-16	
xxxxxxxxxxxxxx	xxxxxxxxxxxxxx	
000uuuuuxxxxxxxxxxxxxxx	110110wwwwxxxxxx 110111xxxxxxxxxxx	

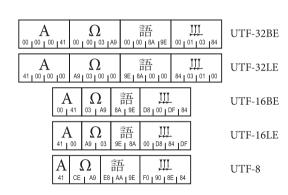
Note: wwww = uuuuu - 1

UTF-8

Code unit 8-битное значение

Table 3-6. UTF-8 Bit Distribution

Scalar Value	First Byte	Second Byte	Third Byte	Fourth Byte
00000000 0xxxxxx	0xxxxxxx			
00000yyy yyxxxxxx	110ууууу	10xxxxxx		
zzzzyyyy yyxxxxxx	1110zzzz	10уууууу	10xxxxxx	
000uuuuu zzzzyyyy yyxxxxxx	11110uuu	10uuzzzz	10уууууу	10xxxxxx



Q&A